Data Pendidikan: Jenis & Preprocessing

Data Mining (MI0439)

Dr. Indira Puteri Kinasih

Daftar Isi

Capaian Pembelajaran . . . 3

Mengapa Data Perlu Dipersiapkan? 3

Data Pendidikan 4

Struktur Data . . . 4
Variabel Numerik . . . 5
Variabel Kategorik . . . 6
Skala pengukuran data . . . 6
Masalah Kualitas Data . . . 7

Preprocessing dalam EDM 7

Data Cleaning . . . 7
Mengapa Preprocessing Penting? . . . 8
Tahapan Preprocessing dalam EDM . . . 8
Prinsip Penting . . . 9
Data Cleaning . . . 9
Duplikasi Data . . . 10
Invalid Value . . . 10
Missing Value . . . 11
Mengapa Missing Value Terjadi? . . . 11
Cara Menangani Missing Value . . . 11
Contoh Mean Imputation . . . 12
Contoh Median Imputation . . . 13
Apakah Missing Value Boleh Langsung Dihapus? . . . 13
Missing Value sebagai Informasi . . . 14

Contoh kasus sederhana **14**
Mini Case: Data Nilai Siswa 15
Pertanyaan 15
Aktivitas Kelompok 16

Diskusi **16**
Situasi A 16
Situasi B 16
Kesalahan yang Sering Terjadi 17
Hubungan dengan Pertemuan Sebelumnya 17

Inti Pembelajaran **18**
Exit Ticket 18

Capaian Pembelajaran

Setelah mengikuti pertemuan ini, mahasiswa diharapkan mampu:

- mengidentifikasi berbagai jenis data dalam konteks pendidikan;
- membedakan data numerik dan kategorik;
- menjelaskan karakteristik data yang baik untuk analisis;
- mengidentifikasi masalah kualitas data;
- menjelaskan konsep *data preprocessing*;
- melakukan *data cleaning* sederhana;
- menjelaskan konsep *missing value* dan cara menanganinya;
- memahami pentingnya preprocessing sebelum menerapkan metode data mining.

Mengapa Data Perlu Dipersiapkan?

Pada pertemuan sebelumnya telah dibahas bahwa **Educational Data Mining (EDM)** menggunakan data pendidikan untuk menemukan pola yang berguna.

Namun, data yang tersedia di dunia nyata biasanya **tidak langsung siap dianalisis**.

Contohnya:

Siswa	Kehadiran	Nilai Kuis	Akses LMS	Status
Ahmad	95	85	20	Aktif
Budi	90	80	15	Aktif
Citra		65	8	Aktif
Deni	105	70		Aktif
Evi	75		5	Tidak Aktif

Perhatikan beberapa masalah:

- terdapat nilai yang kosong;
- kehadiran **105%** tidak masuk akal;
- terdapat perbedaan karakteristik siswa;
- beberapa variabel memiliki skala berbeda;
- data belum tentu memiliki format yang sesuai untuk algoritma.

> **Catatan**
>
> Karena itu, sebelum melakukan data mining, kita perlu melakukan **data preprocessing**. **Garbage in, garbage out.** Jika data yang digunakan buruk, hasil analisis juga berpotensi buruk.

Data Pendidikan

Data pendidikan adalah data yang dikumpulkan dari proses, aktivitas, dan lingkungan pendidikan.

Contohnya:

Jenis Data	Contoh
Data akademik	Nilai tugas, kuis, UTS, UAS, nilai mata pelajaran, nilai remedial
Data kehadiran	Kehadiran, ketidakhadiran, keterlambatan
Data aktivitas belajar	Materi yang dibaca, video ditonton, latihan dikerjakan, waktu belajar
Data interaksi	Diskusi, komentar, forum, interaksi dengan guru, aktivitas kolaborasi
Data karakteristik siswa	Kelas, usia, jenis kelamin, karakteristik akademik
Data sekolah	Kelas, guru, fasilitas, jumlah siswa, karakteristik sekolah
Data digital	Login LMS, klik materi, durasi akses, aktivitas kuis

Struktur Data

Data biasanya disusun dalam bentuk **baris dan kolom**.

Misalnya:

Siswa	Kehadiran	Nilai Kuis	Nilai UTS	Akses LMS
Ahmad	95	85	88	20
Budi	90	80	82	15
Citra	70	65	60	8
Deni	85	75	70	12
Evi	75	60	58	5

Dalam data mining:

- **baris** biasanya merepresentasikan *observasi*;
- **kolom** merepresentasikan *variabel* atau *atribut*.

Pada contoh tersebut:

> Satu baris = satu siswa

sedangkan:

Satu kolom = satu karakteristik siswa.

Variabel Numerik

Variabel numerik memiliki nilai berupa angka yang dapat digunakan dalam operasi matematika.

Contoh:

Variabel	Contoh
Usia	11 tahun
Nilai	85
Kehadiran	95%
Jumlah tugas	12
Durasi belajar	45 menit
Jumlah login	20

Variabel numerik dapat dibedakan menjadi:

Diskrit

Nilainya biasanya berupa hitungan.

Contoh:

- jumlah tugas;
- jumlah login;
- jumlah ketidakhadiran.

Kontinu

Nilainya dapat berada pada suatu rentang.

Contoh:

- waktu belajar;
- tinggi badan;
- berat badan.

Variabel Kategorik

Variabel kategorik menunjukkan kelompok atau kategori.

Contoh:

Variabel	Kategori
Jenis kelamin	Laki-laki, Perempuan
Kelas	IV, V, VI
Status siswa	Aktif, Tidak Aktif
Tingkat risiko	Rendah, Sedang, Tinggi
Jenis sekolah	MI, SD
Metode belajar	Tatap muka, Daring, Blended

Data kategorik tidak selalu dapat diperlakukan sebagai angka.

Misalnya:

```
Laki-laki = 1
Perempuan = 2
```

Angka 1 dan 2 tersebut hanya merupakan **kode**, bukan berarti perempuan memiliki nilai "lebih tinggi" daripada laki-laki.

Skala pengukuran data

Jenis data juga dapat dilihat berdasarkan skala pengukuran.

Skala	Karakteristik	Contoh Pendidikan
Nominal	Kategori tanpa urutan	Jenis kelamin, jenis sekolah
Ordinal	Kategori memiliki urutan	Rendah, sedang, tinggi
Interval	Jarak antarnilai bermakna	Skor tertentu yang berskala interval
Rasio	Memiliki nol absolut	Usia, jumlah tugas, waktu belajar

Pemahaman mengenai skala pengukuran penting karena akan memengaruhi **cara data dianalisis**.

Masalah Kualitas Data

Data pendidikan dapat memiliki berbagai masalah.

Masalah	Contoh
Missing value	Nilai kuis kosong
Duplikasi	Data siswa tercatat dua kali
Inconsistent value	"Laki-laki", "L", "Pria"
Invalid value	Kehadiran 105%
Typo	"Matemtika"
Format berbeda	12/08/2026 dan 2026-08-12
Outlier	Nilai yang sangat berbeda dari sebagian besar data

Masalah-masalah tersebut perlu diperiksa sebelum data digunakan untuk pemodelan.

Preprocessing dalam EDM

Preprocessing adalah tahap menyiapkan data sebelum digunakan dalam analisis atau algoritma data mining. Data pendidikan yang diperoleh dari sekolah, LMS, kuesioner, atau sistem akademik sering kali belum siap digunakan karena mengandung data ganda, nilai yang tidak valid, format yang tidak konsisten, atau data yang hilang.

Tujuan preprocessing adalah menghasilkan data yang:

- **bersih** — kesalahan dan duplikasi ditangani;
- **konsisten** — format dan kategori memiliki bentuk yang seragam;
- **lengkap** — missing value ditangani dengan cara yang sesuai;
- **valid** — nilai berada pada rentang atau kategori yang seharusnya;
- **siap dianalisis** — struktur data sesuai dengan metode yang akan digunakan.

Secara sederhana, alurnya dapat digambarkan sebagai:

Data mentah → Identifikasi masalah → Cleaning → Penanganan missing value → Transformasi → Data siap dianalisis

Data Cleaning

Data cleaning merupakan proses menemukan dan menangani masalah pada data. Dalam EDM, beberapa masalah yang umum ditemukan adalah:

Masalah	Contoh	Penanganan
Duplikasi	Siswa tercatat dua kali	Identifikasi dan hapus duplikasi
Invalid value	Nilai ujian = 150	Periksa dan koreksi/hapus
Format tidak konsisten	`L`, `Laki-laki`, `laki laki`	Samakan kategori
Typo	`Perempuan`, `Perempaun`	Koreksi kategori
Missing value	Nilai kuis kosong	Analisis dan tentukan metode penanganan
Outlier	Waktu belajar = 999 jam	Periksa kewajaran dan sumber data

Mengapa Preprocessing Penting?

Bayangkan kita ingin menggunakan data siswa untuk memprediksi apakah seorang siswa berisiko mengalami kesulitan belajar.

Jika data yang digunakan masih mengandung nilai ujian yang salah, kehadiran yang tidak konsisten, atau missing value yang ditangani secara sembarangan, maka hasil model dapat menjadi tidak akurat.

Dengan demikian:

> **Kualitas hasil data mining sangat dipengaruhi oleh kualitas data yang digunakan.**

Preprocessing juga harus dilakukan dengan hati-hati. Tidak semua data yang aneh harus langsung dihapus. Data yang tampak tidak biasa perlu diperiksa terlebih dahulu untuk menentukan apakah merupakan kesalahan pencatatan, kejadian yang memang terjadi, atau informasi yang justru penting.

Tahapan Preprocessing dalam EDM

Preprocessing dapat dilakukan melalui beberapa tahap:

1. **Memahami data**
   Mengenali variabel, tipe data, jumlah observasi, dan sumber data.
2. **Memeriksa kualitas data**
   Mencari duplikasi, nilai tidak valid, format tidak konsisten, dan missing value.
3. **Melakukan data cleaning**
   Memperbaiki atau menangani masalah yang ditemukan.

4. **Menangani missing value**
   Menentukan apakah data dihapus, diimputasi, atau dipertahankan sebagai informasi.
5. **Melakukan transformasi bila diperlukan**
   Misalnya mengubah kategori menjadi kode numerik atau mengubah format data agar sesuai dengan analisis.
6. **Memeriksa kembali data**
   Memastikan data setelah preprocessing tetap masuk akal dan sesuai dengan tujuan analisis.

Prinsip Penting

Preprocessing bukan berarti membuat data menjadi "sempurna", tetapi membuat data **layak digunakan untuk tujuan analisis tertentu**.

Metode preprocessing yang digunakan juga bergantung pada jenis data dan tujuan data mining.

Data Cleaning

Data cleaning adalah proses mendeteksi dan memperbaiki masalah dalam data.

Tujuannya adalah menghasilkan data yang:

- lebih akurat;
- konsisten;
- lengkap;
- relevan;
- dan siap digunakan untuk analisis.

Contoh:

Sebelum Cleaning	Setelah Cleaning
L	Laki-laki
Pria	Laki-laki
P	Perempuan
Perempuan	Perempuan
Matemtika	Matematika
Matematika	Matematika

Data yang memiliki kategori berbeda tetapi memiliki makna yang sama perlu diseragamkan.

Duplikasi Data

Misalkan terdapat:

ID	Nama	Kelas	Nilai
001	Ahmad	V	80
002	Budi	V	75
003	Ahmad	V	80
004	Citra	V	90

Apakah Ahmad merupakan dua siswa?

Belum tentu.

Kemungkinan data Ahmad tercatat dua kali.

Jika memang merupakan duplikasi, salah satu baris perlu dihapus.

> **Duplikasi dapat menyebabkan jumlah observasi menjadi tidak benar dan memengaruhi hasil analisis.**

Invalid Value

Data juga dapat mengandung nilai yang secara logika tidak mungkin.

Contoh:

Variabel	Nilai	Masalah
Kehadiran	105%	Tidak mungkin
Usia	250 tahun	Tidak masuk akal
Nilai	150	Jika skala maksimum 100
Jumlah tugas	-5	Tidak mungkin

Nilai seperti ini perlu diperiksa.

Namun, jangan langsung menghapusnya.

Pertama-tama tanyakan:

> **Apakah nilai tersebut benar-benar salah atau ada penjelasan lain?**

Missing Value

Missing value adalah kondisi ketika nilai suatu variabel tidak tersedia untuk suatu observasi.

Contoh:

Siswa	Kehadiran	Nilai Kuis	Nilai UAS
Ahmad	95	85	88
Budi	90	80	82
Citra	70	**NA**	60
Deni	**NA**	75	70
Evi	75	60	**NA**

`NA` dapat menunjukkan bahwa data tidak tersedia.

Missing value merupakan masalah penting karena banyak algoritma data mining tidak dapat bekerja langsung dengan data yang kosong.

Mengapa Missing Value Terjadi?

Missing value dapat terjadi karena berbagai alasan.

Penyebab	Contoh
Data tidak dikumpulkan	Nilai kuis tidak tersedia
Siswa tidak mengikuti ujian	Nilai UTS kosong
Kesalahan input	Data tidak tersimpan
Responden tidak menjawab	Kuesioner kosong
Masalah sistem	Data LMS gagal direkam
Tidak relevan	Variabel tertentu tidak berlaku untuk siswa

Karena penyebabnya berbeda, **cara menangani missing value juga tidak selalu sama**.

Cara Menangani Missing Value

Beberapa pendekatan yang umum digunakan:

Pendekatan	Penjelasan
Menghapus observasi	Baris dengan missing value dihapus
Menghapus variabel	Variabel dengan terlalu banyak missing dihapus

Pendekatan	Penjelasan
Mean imputation	Missing diganti dengan rata-rata
Median imputation	Missing diganti dengan median
Mode imputation	Missing kategorik diganti dengan modus
Model-based imputation	Nilai diperkirakan menggunakan model
Multiple imputation	Missing diimputasi menggunakan beberapa nilai yang mungkin

Tidak ada satu metode yang selalu paling baik.

Pemilihan metode bergantung pada:

- jumlah missing value;
- pola missing;
- jenis variabel;
- tujuan analisis;
- karakteristik data.

Contoh Mean Imputation

Misalkan nilai kuis:

```
80
70
90
NA
60
```

Rata-rata nilai yang tersedia:

$$\bar{x} = \frac{80 + 70 + 90 + 60}{4} = 75$$

Maka:

```
80
70
90
75
60
```

Nilai `NA` diganti dengan **75**.

Namun, metode ini memiliki kelemahan karena dapat mengurangi variasi data.

Contoh Median Imputation

Misalkan:

```
50
60
70
80
NA
```

Median data yang tersedia adalah:

$$\text{Median} = 65$$

Maka:

```
50
60
70
80
65
```

Median sering dipertimbangkan ketika data memiliki **outlier** atau distribusi yang tidak simetris.

Apakah Missing Value Boleh Langsung Dihapus?

Tidak selalu.

Misalnya kita memiliki data:

> 1.000 siswa

dan hanya 5 siswa yang tidak memiliki nilai kuis.

Menghapus 5 observasi mungkin tidak terlalu bermasalah.

Tetapi jika:

400 dari 1.000 siswa tidak memiliki nilai kuis,

menghapus seluruh baris dapat menyebabkan kehilangan informasi yang sangat besar.

Karena itu, sebelum menghapus missing value, perlu ditanyakan:

> **Berapa banyak data yang hilang?**

dan

> **Mengapa data tersebut hilang?**

Missing Value sebagai Informasi

Missing value terkadang justru memiliki makna.

Misalnya dalam data pendidikan:

> Siswa yang tidak memiliki nilai ujian mungkin bukan karena data hilang secara acak, tetapi karena siswa tersebut tidak mengikuti ujian.

Jika semua nilai tersebut langsung diganti dengan rata-rata, informasi penting dapat hilang.

Karena itu:

> **Missing value bukan sekadar masalah teknis, tetapi juga dapat mengandung informasi tentang proses pengumpulan data.**

Contoh kasus sederhana

Misalkan kita mendapatkan data:

Siswa	Kehadiran	Nilai	Jenis Kelamin
Ahmad	95	85	L
Budi	90	NA	L
Citra	105	75	P
Deni	80	70	L
Evi	NA	65	Perempuan

Kita menemukan:

- `NA` pada nilai;
- `NA` pada kehadiran;

- kehadiran 105%;
- kategori jenis kelamin tidak konsisten.

Setelah preprocessing, misalnya:

Siswa	Kehadiran	Nilai	Jenis Kelamin
Ahmad	95	85	Laki-laki
Budi	90	75	Laki-laki
Citra	100	75	Perempuan
Deni	80	70	Laki-laki
Evi	89	65	Perempuan

Data sekarang lebih siap digunakan dalam analisis.

Catatan: nilai hasil imputasi di atas hanya ilustrasi.

Mini Case: Data Nilai Siswa

Perhatikan data berikut.

Siswa	Kehadiran	Tugas	Kuis	UTS
A	95	90	85	88
B	90	80	75	82
C		70	65	60
D	105	85	80	78
E	80		60	65
F	75	60	55	50

Pertanyaan

Identifikasi:

- variabel numerik;
- variabel kategorik jika ada;
- missing value;
- invalid value;
- kemungkinan masalah lain.

Kemudian diskusikan:

> **Apa yang harus dilakukan terhadap setiap masalah tersebut sebelum data digunakan untuk data mining?**

Aktivitas Kelompok

Kegiatan: Setiap kelompok akan mendapatkan sebuah dataset pendidikan sederhana.

Tugas kelompok:

Tahapan	Pertanyaan
Identifikasi	Data apa saja yang tersedia?
Struktur	Mana observasi dan mana variabel?
Tipe data	Mana yang numerik dan kategorik?
Cleaning	Apakah terdapat data yang tidak konsisten?
Missing	Apakah terdapat missing value?
Validitas	Apakah terdapat nilai yang tidak masuk akal?
Solusi	Bagaimana setiap masalah akan ditangani?

Setiap kelompok kemudian menjelaskan **alasan** di balik keputusan preprocessing yang mereka ambil.

Diskusi

Perhatikan dua situasi berikut.

Situasi A

Dari 1.000 siswa, hanya 5 siswa yang tidak memiliki nilai kuis.

Situasi B

Dari 1.000 siswa, 400 siswa tidak memiliki nilai kuis.

Apakah keduanya sebaiknya ditangani dengan cara yang sama?

Mengapa?

Kesalahan yang Sering Terjadi

Beberapa kesalahan umum dalam preprocessing:

> **Menghapus semua baris yang memiliki missing value tanpa memeriksa jumlahnya.**
>
> **Mengganti semua missing value dengan rata-rata tanpa memahami penyebab missing.**
>
> **Menghapus outlier hanya karena nilainya terlihat berbeda.**
>
> **Menganggap angka sebagai data numerik tanpa melihat maknanya.**
>
> **Melakukan preprocessing tanpa mempertimbangkan tujuan analisis.**

Preprocessing bukan sekadar "membersihkan data", tetapi merupakan bagian dari proses analisis yang membutuhkan pertimbangan.

Hubungan dengan Pertemuan Sebelumnya

Pada pertemuan pertama kita membahas:

```
Data Pendidikan
       ↓
KDD
       ↓
Data Mining
       ↓
Pola / Pengetahuan
```

Sekarang kita melihat bahwa terdapat tahapan penting sebelum data mining:

```
Data Pendidikan
       ↓
Selection
       ↓
Preprocessing
       ↓
Transformation
       ↓
Data Mining
       ↓
```

```
Evaluation
       ↓
Knowledge
```

Dengan demikian:

> **Kualitas hasil data mining sangat dipengaruhi oleh kualitas data yang digunakan.**

Inti Pembelajaran

Hal-hal yang perlu diingat:

Konsep	Inti
Data pendidikan	Data yang dihasilkan dari proses dan lingkungan pendidikan
Data numerik	Data yang direpresentasikan dalam bentuk angka
Data kategorik	Data yang menunjukkan kategori atau kelompok
Data cleaning	Proses memperbaiki masalah kualitas data
Missing value	Nilai yang tidak tersedia
Preprocessing	Serangkaian proses menyiapkan data sebelum analisis
Tujuan preprocessing	Menghasilkan data yang lebih valid, konsisten, dan siap dianalisis

Exit Ticket

Jawab secara singkat:

Apa perbedaan antara data cleaning dan data preprocessing?

Mengapa missing value tidak boleh langsung dihapus tanpa diperiksa terlebih dahulu?

Sebutkan tiga masalah kualitas data yang mungkin ditemukan dalam data pendidikan.

Jika Anda memiliki data 1.000 siswa dan 5% nilai kuis hilang, apa yang akan Anda lakukan? Jelaskan alasannya.