Exploratory Data Analysis (EDA)

Data Mining (MI0439)

Dr. Indira Puteri Kinasih

Daftar Isi

Capaian Pembelajaran . . . 3
Mengapa Data Perlu Dieksplorasi? . . . 3
Apa itu EDA? . . . 4

Exploratory Data Analysis (EDA) **4**
Statistik Deskriptif . . . 5
Mean & Median . . . 5
Ukuran Penyebaran . . . 6
Statistik Deskriptif dengan R . . . 7
Ringkasan Data dengan `summary()` . . . 8
Visualisasi Data . . . 8
Korelasi . . . 12
Eksplorasi Satu Variabel . . . 13
Eksplorasi Dua Variabel . . . 13
Contoh: Eksplorasi data siswa . . . 14
Apa yang dapat kita eksplorasi? . . . 14

Catatan penting **14**
Pentingnya interpretasi . . . 14
Kesalahan yang Sering Terjadi . . . 15

Penugasan Kelompok **15**
Eksplorasi Dataset Pendidikan . . . 15
Tahap Pengerjaan . . . 16
Temukan Cerita dari Data . . . 16
Pertanyaan Panduan . . . 17
Output/Luaran Kelompok . . . 17
Presentasi Singkat . . . 18
Prinsip Utama . . . 18

Capaian Pembelajaran

Setelah mengikuti pertemuan ini, mahasiswa mampu:

- menjelaskan konsep dasar **Exploratory Data Analysis (EDA)**;
- menggunakan statistik deskriptif untuk memahami karakteristik data pendidikan;
- memilih visualisasi yang sesuai dengan jenis data;
- menginterpretasikan hasil statistik dan visualisasi;
- melakukan eksplorasi sederhana terhadap dataset pendidikan.

Mengapa Data Perlu Dieksplorasi?

Pada pertemuan sebelumnya, kita telah mempelajari bagaimana **mengidentifikasi dan menangani masalah pada data pendidikan**.

Data yang telah dibersihkan belum tentu langsung memberikan informasi yang mudah dipahami.

Misalnya, kita memiliki data:

- nilai tugas;
- nilai kuis;
- kehadiran;
- waktu belajar;
- aktivitas LMS;
- nilai ujian.

Kita mungkin ingin mengetahui:

> Apakah nilai siswa cenderung tinggi atau rendah?
>
> Bagaimana distribusi nilai siswa?
>
> Apakah terdapat siswa dengan nilai yang sangat berbeda?
>
> Apakah siswa dengan kehadiran tinggi cenderung memiliki nilai yang lebih baik?
>
> Apakah siswa yang aktif menggunakan LMS memiliki hasil belajar yang berbeda?

Untuk menjawab pertanyaan awal tersebut, kita membutuhkan **Exploratory Data Analysis (EDA)**.

Apa itu EDA?

Exploratory Data Analysis (EDA) adalah proses mengeksplorasi data untuk memahami karakteristik, pola, hubungan, dan kemungkinan masalah dalam data.

EDA membantu kita menemukan:

- karakteristik data;
- distribusi data;
- pola;
- perbedaan antar kelompok;
- hubungan antarvariabel;
- nilai yang tidak biasa;
- pertanyaan yang dapat dianalisis lebih lanjut.

Secara sederhana:

> **EDA membantu kita bertanya kepada data: "Apa yang sebenarnya ada di dalam data ini?"**

EDA tidak hanya membuat grafik. EDA menggabungkan:

Data → Statistik Deskriptif → Visualisasi → Interpretasi → Pertanyaan Baru

Exploratory Data Analysis (EDA)

Dalam **Educational Data Mining (EDM)**, EDA dapat digunakan untuk memahami perilaku dan hasil belajar siswa.

Pertanyaan	Data	Analisis
Bagaimana distribusi/sebaran nilai siswa?	Nilai UAS	Histogram, mean, median
Berapa banyak siswa yang aktif di LMS?	Aktivitas LMS	Bar chart
Bagaimana penyebaran nilai?	Nilai UAS	Boxplot
Apakah waktu belajar berkaitan dengan nilai?	Waktu belajar + nilai	Scatter plot
Apakah nilai berbeda berdasarkan aktivitas LMS?	Aktivitas LMS + nilai	Boxplot

EDA dapat membantu peneliti atau pendidik menentukan **pertanyaan yang lebih spesifik** untuk tahap analisis berikutnya.

Statistik Deskriptif

Statistik deskriptif digunakan untuk meringkas data sehingga karakteristiknya lebih mudah dipahami.

Ukuran	Fungsi
Jumlah data (`n`)	Mengetahui banyaknya observasi
Minimum	Nilai terkecil
Maksimum	Nilai terbesar
Mean	Nilai rata-rata
Median	Nilai tengah
Kuartil	Menunjukkan posisi data dalam distribusi
Standar deviasi	Menggambarkan penyebaran data

Mean & Median

Mean atau rata-rata dihitung dengan:

$$\bar{x} = \frac{1}{n} \sum_{i=1}^{n} x_i$$

Misalnya nilai lima siswa:

$$70,\ 75,\ 80,\ 85,\ 90$$

maka:

$$\bar{x} = \frac{70 + 75 + 80 + 85 + 90}{5} = 80$$

Mean memberikan gambaran mengenai **pusat data**. Namun, mean dapat dipengaruhi oleh nilai yang sangat ekstrem.

Median adalah nilai tengah setelah data diurutkan.

Contoh:

$$60,\ 70,\ 75,\ 80,\ 95$$

Median = **75**.

Jika jumlah data genap, median diperoleh dari rata-rata dua nilai tengah.

Median dapat memberikan gambaran yang lebih representatif ketika terdapat nilai ekstrem.

Perhatikan data berikut:

$$60,\ 65,\ 70,\ 75,\ 200$$

Mean:

$$\bar{x} = 94$$

Sedangkan median:

$$70$$

Nilai **200** membuat mean menjadi jauh lebih tinggi daripada sebagian besar data.

Karena itu, dalam EDA kita sebaiknya tidak hanya melihat mean.

> **Mean dan median dapat memberikan informasi yang berbeda mengenai pusat data.**

Ukuran Penyebaran

Mengetahui rata-rata saja belum cukup.

Perhatikan dua kelompok berikut.

Kelas A

$$78,\ 79,\ 80,\ 81,\ 82$$

Kelas B

$$60,\ 70,\ 80,\ 90,\ 100$$

Keduanya memiliki rata-rata yang sama, tetapi penyebaran nilainya berbeda.

Salah satu ukuran penyebaran adalah **standar deviasi**.

- Standar deviasi kecil $\rightarrow$ data cenderung dekat dengan rata-rata.
- Standar deviasi besar $\rightarrow$ data lebih menyebar.

Statistik Deskriptif dengan R

Misalkan kita memiliki data nilai UAS:

```
nilai_uas <- c(
  82, 80, 72, 94, 65,
  78, 86, 90, 68, 92,
  70, 81, 85, 89, 58
)
```

Mean:

```
mean(nilai_uas)
```

```
[1] 79.33333
```

Median:

```
median(nilai_uas)
```

```
[1] 81
```

Standar deviasi:

```
sd(nilai_uas)
```

```
[1] 10.6949
```

Nilai minimum dan maksimum:

```
min(nilai_uas)
```

```
[1] 58
```

```
max(nilai_uas)
```

```
[1] 94
```

Ringkasan Data dengan `summary()`

R menyediakan fungsi `summary()` untuk memperoleh ringkasan statistik secara cepat.

```
summary(nilai_uas)
```

```
   Min. 1st Qu.  Median    Mean 3rd Qu.    Max.
  58.00   71.00   81.00   79.33   87.50   94.00
```

Output akan memberikan:

- Minimum
- Kuartil pertama
- Median
- Mean
- Kuartil ketiga
- Maksimum

Fungsi ini sangat berguna sebagai langkah awal EDA.

Visualisasi Data

Visualisasi membantu kita melihat pola yang sulit dikenali hanya dari angka.

Pemilihan grafik harus disesuaikan dengan **jenis data dan pertanyaan yang ingin dijawab**.

Tujuan	Jenis data	Visualisasi
Melihat distribusi	Numerik	Histogram
Membandingkan frekuensi kategori	Kategorik	Bar chart
Melihat penyebaran	Numerik	Boxplot
Membandingkan kelompok	Numerik + kategorik	Boxplot
Melihat hubungan	Numerik + numerik	Scatter plot

Histogram

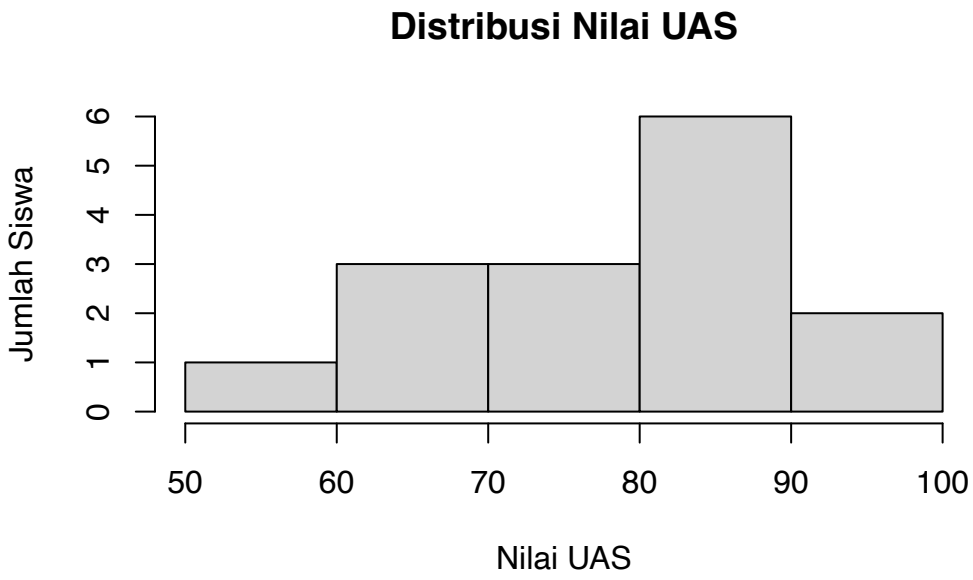
Histogram digunakan untuk melihat **distribusi variabel numerik**.

Contohnya:

- nilai ujian;
- nilai tugas;

- waktu belajar;
- jumlah aktivitas LMS.

```
hist(
  nilai_uas,
  main = "Distribusi Nilai UAS",
  xlab = "Nilai UAS",
  ylab = "Jumlah Siswa"
)
```



Histogram membantu kita melihat:

- di mana sebagian besar data berada;
- apakah data cenderung simetris;
- apakah terdapat nilai ekstrem;
- apakah distribusi memiliki pola tertentu.

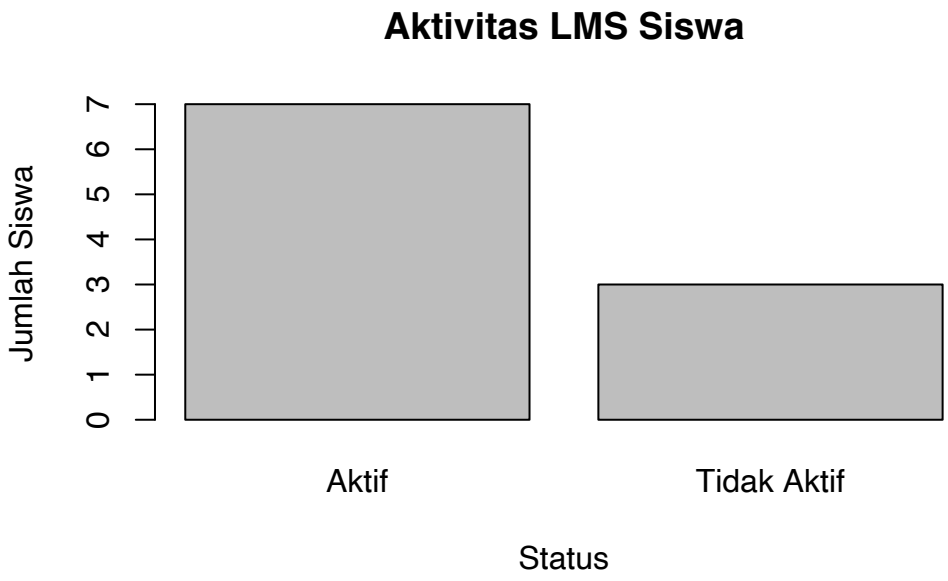
Bar Chart

Bar chart digunakan terutama untuk melihat **frekuensi kategori**.

Misalnya status aktivitas LMS:

```r
aktivitas <- c(
  "Aktif", "Aktif", "Aktif", "Tidak Aktif", "Aktif",
  "Tidak Aktif", "Aktif", "Aktif", "Tidak Aktif", "Aktif"
)

barplot(
  table(aktivitas),
  main = "Aktivitas LMS Siswa",
  xlab = "Status",
  ylab = "Jumlah Siswa"
)
```



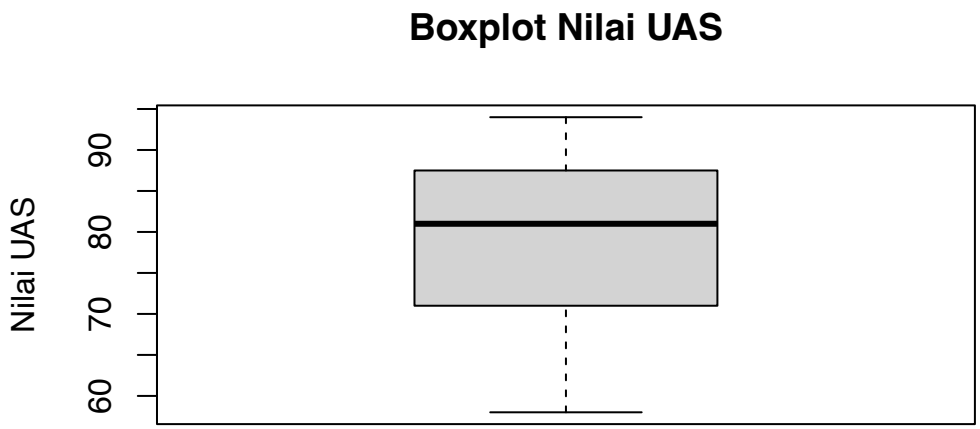
Dari grafik tersebut kita dapat melihat jumlah siswa dalam setiap kategori.

Boxplot

Boxplot digunakan untuk melihat:

- median;
- kuartil;
- penyebaran data;
- kemungkinan nilai ekstrem.

```r
boxplot(
  nilai_uas,
  main = "Boxplot Nilai UAS",
  ylab = "Nilai UAS"
)
```



Boxplot juga berguna untuk membandingkan distribusi nilai antar kelompok.

Scatter Plot

Scatter plot digunakan untuk melihat pola hubungan antara **dua variabel numerik**.

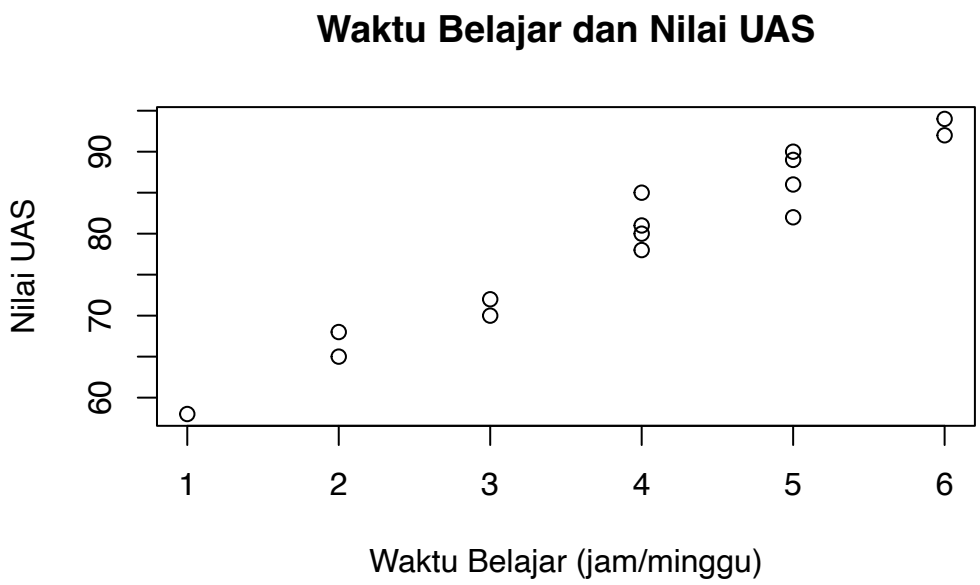
Misalnya:

> Apakah waktu belajar berkaitan dengan nilai UAS?

```r
waktu_belajar <- c(
  5, 4, 3, 6, 2,
  4, 5, 5, 2, 6,
  3, 4, 4, 5, 1
)

plot(
```

```
  waktu_belajar,
  nilai_uas,
  main = "Waktu Belajar dan Nilai UAS",
  xlab = "Waktu Belajar (jam/minggu)",
  ylab = "Nilai UAS"
)
```



Perhatikan apakah titik-titik menunjukkan pola tertentu.

Korelasi

Jika scatter plot menunjukkan bahwa siswa dengan waktu belajar lebih tinggi cenderung memiliki nilai lebih tinggi, kita dapat mengatakan:

> **Terdapat pola hubungan antara waktu belajar dan nilai.**

Namun, kita belum dapat langsung menyimpulkan:

> **Waktu belajar menyebabkan nilai siswa meningkat.**

Hubungan atau korelasi tidak selalu menunjukkan sebab-akibat.

Bisa terdapat faktor lain, seperti:

- motivasi belajar;
- kemampuan awal;
- dukungan orang tua;
- kualitas pembelajaran;
- akses terhadap sumber belajar.

Eksplorasi Satu Variabel

Eksplorasi satu variabel disebut **univariate analysis**.

Contoh variabel numerik:

- nilai UAS;
- nilai tugas;
- kehadiran;
- waktu belajar.

Contoh variabel kategorik:

- jenis kelamin;
- status aktivitas LMS;
- kelas;
- kategori kehadiran.

Pertanyaan utama:

> **"Bagaimana karakteristik variabel ini?"**

Eksplorasi Dua Variabel

Kita juga dapat mengeksplorasi dua variabel untuk menemukan pola atau hubungan.

Variabel 1	Variabel 2	Visualisasi
Kehadiran	Nilai UAS	Scatter plot
Waktu belajar	Nilai UAS	Scatter plot
Aktivitas LMS	Nilai UAS	Boxplot
Kelas	Nilai UAS	Boxplot
Status LMS	Jumlah siswa	Bar chart

Pertanyaan berubah dari:

> **"Bagaimana distribusi nilai?"**

menjadi:

> **"Apakah nilai menunjukkan pola tertentu berdasarkan variabel lain?"**

Contoh: Eksplorasi data siswa

Perhatikan dataset berikut

ID	JK	Kehadiran	Nilai Tugas	Nilai Kuis	Waktu Belajar	Aktivitas LMS	Nilai UAS
S001	L	95	85	80	5	Aktif	82
S002	P	90	78	75	4	Aktif	80
S003	L	85	70	68	3	Aktif	72
S004	P	98	92	90	6	Aktif	94
S005	L	75	60	55	2	Tidak Aktif	65
S006	P	88	80	78	4	Aktif	78
S007	L	92	85	82	5	Aktif	86
S008	P	95	88	85	5	Aktif	90
S009	L	80	72	70	2	Tidak Aktif	68
S010	P	95	90	88	6	Aktif	92
S011	P	85	75	72	3	Tidak Aktif	70
S012	L	90	80	78	4	Aktif	81
S013	P	88	82	80	4	Aktif	85
S014	P	94	87	84	5	Aktif	89
S015	L	70	55	50	1	Tidak Aktif	58

Apa yang dapat kita eksplorasi?

- **Distribusi** → Bagaimana sebaran nilai UAS?
- **Perbandingan** → Apakah nilai UAS berbeda menurut JK?
- **Hubungan** → Apakah waktu belajar berkaitan dengan nilai UAS?

Pertanyaan → Statistik → Visualisasi → Interpretasi

Catatan penting

Pentingnya interpretasi

Ingatlah untuk selalu melakukan interpretasi terhadap tabel, gambar, atau grafik. Karena dalam EDA, membuat grafik bukan tujuan akhir. Kita harus mampu menjelaskan **apa yang**

ditunjukkan oleh grafik.

Contoh interpretasi:

> Histogram menunjukkan bahwa sebagian besar nilai UAS berada pada rentang 70–90, sedangkan beberapa siswa memperoleh nilai di bawah 60.

Lebih baik daripada:

> Histogram nilai UAS telah dibuat.

EDA membutuhkan **interpretasi terhadap informasi yang ditampilkan oleh data**.

Kesalahan yang Sering Terjadi

Kesalahan	Masalah
Membuat grafik tanpa interpretasi	Tidak menghasilkan informasi
Menggunakan grafik yang tidak sesuai	Data sulit dibaca
Hanya melihat mean	Distribusi data dapat terabaikan
Mengabaikan outlier	Pola dapat disalahartikan
Menganggap korelasi sebagai sebab-akibat	Kesimpulan terlalu jauh
Menghapus data tanpa alasan	Informasi dapat hilang
Membuat terlalu banyak grafik	Eksplorasi menjadi tidak fokus

Penugasan Kelompok

Eksplorasi Dataset Pendidikan

Setiap kelompok akan memperoleh **satu dataset pendidikan** yang berbeda. Dataset tersebut menggambarkan berbagai kondisi pembelajaran, aktivitas siswa, maupun hasil belajar.

Dataset yang diberikan **belum sepenuhnya siap untuk dianalisis**. Oleh karena itu, kelompok perlu melakukan **data cleaning** sebelum melanjutkan ke tahap **Exploratory Data Analysis (EDA)**.

Tahap Pengerjaan

Data Cleaning

Periksa dataset untuk menemukan permasalahan kualitas data, seperti:

- missing value;
- data duplikat;
- nilai yang tidak valid;
- kesalahan atau ketidakkonsistenan penulisan;
- nilai yang tidak wajar atau ekstrem;
- ketidaksesuaian tipe data.

Lakukan perbaikan yang diperlukan dan **jelaskan keputusan yang diambil**.

> Jangan langsung menghapus data yang bermasalah. Tentukan terlebih dahulu jenis masalah dan alasan mengapa suatu tindakan diperlukan.

Exploratory Data Analysis

Setelah data dibersihkan, lakukan eksplorasi untuk memahami karakteristik dataset.

Gunakan:

- statistik deskriptif;
- tabel frekuensi;
- visualisasi yang sesuai dengan jenis data;
- perbandingan antar kelompok;
- eksplorasi hubungan antarvariabel.

Minimal buat **4 visualisasi**, dengan mempertimbangkan jenis data dan pertanyaan yang ingin dijawab.

Temukan Cerita dari Data

Jangan berhenti pada pembuatan tabel dan grafik.

Setiap kelompok harus menemukan minimal **3 temuan penting** dari dataset.

Setiap temuan harus disertai:

Temuan → Bukti dari Data → Interpretasi

Contoh:

Temuan: Siswa yang lebih aktif menggunakan LMS cenderung memiliki nilai kuis yang lebih tinggi.

Bukti: Kelompok siswa aktif memiliki median nilai kuis yang lebih tinggi dibandingkan kelompok tidak aktif.

Interpretasi: Aktivitas LMS menunjukkan pola yang berkaitan dengan hasil kuis. Namun, pola ini belum dapat digunakan untuk menyimpulkan hubungan sebab-akibat.

Pertanyaan Panduan

Gunakan pertanyaan berikut untuk membantu eksplorasi:

- Bagaimana karakteristik utama dataset?
- Apakah terdapat masalah pada data?
- Bagaimana distribusi variabel numerik?
- Bagaimana komposisi variabel kategorik?
- Apakah terdapat nilai yang tidak biasa?
- Apakah terdapat perbedaan antar kelompok?
- Apakah terdapat hubungan atau pola menarik antarvariabel?
- Apa temuan paling penting yang dapat diperoleh dari dataset?

Tidak semua pertanyaan harus dijawab. **Pilih pertanyaan yang relevan dengan dataset kelompok masing-masing.**

Output/Luaran Kelompok

Setiap kelompok mengumpulkan:

Output	Keterangan
Dataset bersih	Dataset setelah proses cleaning
Catatan cleaning	Masalah yang ditemukan dan tindakan yang dilakukan
Statistik deskriptif	Ringkasan karakteristik data
Visualisasi	Minimal 4 grafik yang relevan
Temuan	Minimal 3 temuan utama
Interpretasi	Penjelasan makna setiap temuan

Presentasi Singkat

Setiap kelompok mempresentasikan hasil eksplorasinya secara singkat.

Presentasi tidak perlu menjelaskan seluruh isi dataset. Fokuskan pada:

> **Masalah Data → Proses Cleaning → Hasil EDA → Temuan Utama**

Kelompok juga harus siap menjelaskan **mengapa memilih visualisasi dan metode statistik tertentu**.

Prinsip Utama

> **Data cleaning memastikan data layak dianalisis.**
>
> **EDA membantu kita memahami apa yang terdapat di dalam data.**
>
> **Interpretasi membantu kita mengubah hasil analisis menjadi informasi yang bermakna.**

Exit Ticket

1. Apa satu hal baru yang Anda temukan dari dataset hari ini?
2. Visualisasi apa yang paling tepat untuk mengetahui hubungan antara waktu belajar dan nilai UAS? Mengapa?
3. Apa perbedaan antara “membuat grafik” dan “melakukan EDA”?